


ESCUELA MILITAR DE INGENIERÍA
MCAL. ANTONIO JOSÉ DE SUCRE
“BOLIVIA”



MATERIA : Business Intelligence y Big Data
TEMA : Laboratorio I: Fundamentos y tipos de información
CÓDIGO SAGA : A16237-X
ESTUDIANTE : Tte. AAO Jhafet Abraham Kantuta Goitia
DOCENTE : Ing. Yaqueline Bellot Soliz
FECHA : 09 de agosto de 2026

SANTA CRUZ

Laboratorio I: Fundamentos y tipos de información

1. INTRODUCCIÓN

El presente laboratorio empleamos el dataset online **Retail II**, correspondiente a transacciones de un comercio electrónico de compras. A partir de este se identifican tres fuentes principales: las transacciones de ventas, el catalogo de productos y las reseñas de los clientes.

Esta información será clasificada según su tipo de información y diseñaremos prototipos utilizando modelo relacional SQL, un JSON y una colección en MongoDB, según las indicaciones de la guía de Laboratorio

2. DESARROLLO

PARTE I – EXPLORACIÓN DEL DATASET DEL PROYECTO

1.1 Dataset Online Retail II

Las principales columnas utilizadas en el laboratorio son:

- **InvoiceNo:** número o código de la factura.
- **StockCode:** código de identificación del producto.
- **Description:** descripción del producto.
- **Quantity:** cantidad de unidades adquiridas.
- **InvoiceDate:** fecha y hora en la que se realizó la transacción.
- **Price:** precio unitario del producto.
- **CustomerID:** identificador del cliente.
- **Country:** país asociado al cliente o transacción.

1.2 Fuentes adicionales de información

Si el comercio electrónico funcionara actualmente como un sistema real, las transacciones no serían la única fuente de información.

También existirían otras fuentes, entre ellas:

Catálogo de productos

Contendría información relacionada con los productos disponibles para la venta.

Cada producto podría tener características diferentes. Por ejemplo:

- Material.
- Color.
- Dimensiones.
- Marca.
- Categoría.
- Peso.

- Talla.
- Capacidad.
- Imágenes.
- Especificaciones técnicas.

Debido a que no todos los productos poseen los mismos atributos, esta información puede considerarse semiestructurada.

Reseñas de clientes

Los clientes podrían escribir opiniones después de realizar una compra.

Por ejemplo:

“Excelente calidad, llegó a tiempo y bien empacado.”

La extensión, palabras, significado y contenido del comentario cambiara completamente entre un cliente y otro, por lo que el contenido principal corresponde a información no estructurada.

1.3 Fuentes de datos identificadas para el proyecto

A partir de la exploración del dataset Online Retail II y del análisis de cómo funcionaría un comercio electrónico en un entorno real, se identificaron tres fuentes principales de información que serán utilizadas durante el proyecto integrador.

Transacciones de venta: constituyen la fuente principal disponible en el dataset Online Retail II. Contienen los registros de las operaciones comerciales realizadas, incluyendo número de factura, producto vendido, cantidad, fecha de la transacción, precio, cliente y país. Estos datos permitirían posteriormente realizar análisis relacionados con ventas, comportamiento de clientes, productos más comercializados e ingresos.

Catálogo de productos: corresponde a la información descriptiva de los artículos disponibles en el comercio electrónico. Además de datos básicos como código, nombre y categoría, cada producto puede presentar características particulares, como material, color, dimensiones, talla, capacidad o especificaciones técnicas. Por esta razón, sus atributos pueden variar considerablemente entre diferentes categorías de productos.

Reseñas o comentarios de clientes: representan las opiniones que los compradores podrían realizar sobre los productos adquiridos. Esta fuente incluiría principalmente comentarios escritos en lenguaje natural y podría complementarse con información como el identificador del cliente, código del producto, fecha de publicación y calificación otorgada.

La identificación de estas tres fuentes permite trabajar con diferentes características de los datos dentro de un mismo caso de comercio electrónico y sirve como punto de partida para determinar posteriormente su clasificación y la tecnología de almacenamiento más adecuada.

PARTE II – CLASIFICACIÓN DE FUENTES DE DATOS

Fuente de datos	Tipo de información	Tecnología sugerida	Justificación
Transacciones de venta – Online Retail II	Estructurada	SQL Server	Cada transacción presenta campos previamente definidos, como factura, producto, cantidad, fecha, precio, cliente y país.
Catálogo de productos	Semiestructurada	MongoDB / JSON	Los productos pueden presentar atributos diferentes dependiendo de su categoría sin exigir que todos los productos tengan exactamente los mismos campos.
Reseñas de clientes	No estructurada	MongoDB / almacenamiento documental	El comentario principal está compuesto por texto libre cuyo contenido, extensión y estructura son variables.

PARTE III – PROTOTIPO DE ALMACENAMIENTO ESTRUCTURADO

```

SQLQuery1.s...antuta (80))* ✕
1 CREATE DATABASE BI_OnlineRetail;
2 GO
3
4 USE BI_OnlineRetail;
5 GO
6
7
8 SELECT TOP 20 *
9 FROM VentasImportada;

```

Importar archivo plano "BI_OnlineRetail"


Modificar columnas

Introducción

Especificar archivo de entrada

Vista previa de los datos

Modificar columnas

Resumen

Resultados

Modificar columnas

Esta operación generó el siguiente esquema de tabla. Compruebe si el esquema es preciso y, si no lo es, haga las oportunas modificaciones.

Nombre de columna	Tipo de datos	Clave principal	☒ Permitir valores NULL
Invoice	nvarchar(50)	☐	☒
StockCode	nvarchar(50)	☐	☒
Description	nvarchar(50)	☐	☒
Quantity	int	☐	☒
InvoiceDate	datetime	☐	☒
Price	decimal(18, 10)	☐	☒
Customer_ID	int	☐	☒
Country	nvarchar(50)	☐	☒

Granularidad de la fila del informe de errores (impacto en el rendimiento con intervalos más pequeños) Ningún intervalo

Anterior
Siguiente >
Cancelar

8

9

SELECT TOP 20 *
FROM VentasImportada;

132 %
1
0
↑
↓
Línea: 6, Carácter: 1
TABULACIONES
LF
UTF-8

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price
3	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	2010-12-01 08:26:00.000	2.7500000000
4	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	2010-12-01 08:26:00.000	3.3900000000
5	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	2010-12-01 08:26:00.000	3.3900000000
6	536365	22752	SET 7 BABUSHKA NESTING BOXES	2	2010-12-01 08:26:00.000	7.6500000000
7	536365	21730	GLASS STAR FROSTED T-LIGHT HOLDER	6	2010-12-01 08:26:00.000	4.2500000000
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00.000	1.8500000000
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-01 08:28:00.000	1.8500000000
10	536368	22960	JAM MAKING SET WITH JARS	6	2010-12-01 08:34:00.000	4.2500000000
11	536368	22913	RED COAT RACK PARIS FASHION	3	2010-12-01 08:34:00.000	4.9500000000
12	536368	22912	YELLOW COAT RACK PARIS FASHION	3	2010-12-01 08:34:00.000	4.9500000000
13	536368	22914	BLUE COAT RACK PARIS FASHION	3	2010-12-01 08:34:00.000	4.9500000000
14	536367	84879	ASSORTED COLOUR BIRD ORNAMENT	32	2010-12-01 08:34:00.000	1.6900000000
15	536367	22745	POPPY'S PLAYHOUSE BEDROOM	6	2010-12-01 08:34:00.000	2.1000000000
16	536367	22748	POPPY'S PLAYHOUSE KITCHEN	6	2010-12-01 08:34:00.000	2.1000000000
17	536367	22749	FELTCRAFT PRINCESS CHARLOTTE DOLL	8	2010-12-01 08:34:00.000	3.7500000000
18	536367	22310	IVORY KNITTED MUG COSY	6	2010-12-01 08:34:00.000	1.6500000000
19	536367	84969	BOX OF 6 ASSORTED COLOUR TEASPOONS	6	2010-12-01 08:34:00.000	4.2500000000
20	536367	22623	BOX OF VINTAGE JIGSAW BLOCKS	3	2010-12-01 08:34:00.000	4.9500000000

Para el almacenamiento de las transacciones de venta se utilizó el dataset **Online Retail II**, previamente convertido de formato XLSX a CSV e importado a SQL Server. Durante el proceso de importación, SQL Server identificó las ocho columnas que conforman cada registro de venta y asignó un tipo de dato apropiado a cada una.

Invoice — nvarchar(50)

Representa el número de factura asociado a cada transacción. Se utiliza un tipo de dato de texto debido a que los identificadores de factura pueden contener tanto números como caracteres alfabéticos. Esta columna permite relacionar los distintos productos que forman parte de una misma operación de compra.

StockCode — nvarchar(50)

Contiene el código utilizado para identificar cada producto dentro del catálogo. Se almacena como texto debido a que los códigos de productos pueden ser alfanuméricos.

Description — nvarchar(255)

Almacena la descripción o nombre del producto adquirido. Se utiliza nvarchar para permitir el almacenamiento de caracteres de texto y facilitar la compatibilidad con diferentes símbolos y caracteres.

Quantity — int

Representa la cantidad de unidades del producto incluidas en la transacción. El tipo int resulta adecuado porque este atributo almacena valores numéricos enteros.

InvoiceDate — datetime

Registra la fecha y hora exactas en las que se realizó la transacción. Este campo permite posteriormente efectuar análisis temporales, como ventas por día, mes, año u horario.

Price — decimal(18,10)

Representa el precio unitario del producto registrado en cada transacción. Se utiliza el tipo decimal porque permite almacenar valores numéricos con decimales manteniendo precisión, característica especialmente importante para información monetaria.

Customer_ID — int


Contiene el identificador numérico del cliente asociado a la transacción. Se permite que este campo tenga valores NULL, debido a que dentro del dataset pueden existir registros en los que el cliente no se encuentre identificado.

Country — nvarchar(50)

Indica el país asociado al cliente o a la operación comercial. Su almacenamiento como texto permitirá realizar posteriormente agrupaciones y análisis geográficos de las ventas.

En conjunto, estas columnas conforman una fuente de **información estructurada**, debido a que todos los registros siguen un esquema previamente definido compuesto por columnas, tipos de datos y valores claramente identificables. Esta característica hace que un sistema gestor de bases de datos relacional como SQL Server sea apropiado para su almacenamiento y posterior análisis.

PARTE IV – PROTOTIPO DE ALMACENAMIENTO SEMIESTRUCTURADO



Para representar el catálogo de productos se utilizó MongoDB, debido a que este motor NoSQL documental permite almacenar información mediante documentos con una estructura flexible.

Cada producto conserva algunos campos comunes, como StockCode, Description y Categoría. Sin embargo, el contenido del objeto Atributos puede variar según las características particulares de cada producto.

Por ejemplo, un artículo de decoración puede incluir material y dimensiones, una prenda puede contener talla y material, mientras que un dispositivo electrónico puede incorporar atributos como Bluetooth, autonomía o cancelación de ruido.

Esta característica permite representar productos heterogéneos dentro de una misma colección sin necesidad de definir previamente todas las posibles columnas, como ocurriría en una estructura relacional rígida.


PARTE V – PROTOTIPO DE ALMACENAMIENTO NO ESTRUCTURADO

Para representar las reseñas realizadas por los clientes se utilizó una colección denominada resenas en MongoDB. Cada documento almacena información que permite identificar al cliente y al producto relacionado con la opinión, además del comentario escrito libremente por el usuario.

Los campos CustomerID, StockCode, Calificacion y Fecha poseen una estructura definida. Sin embargo, el campo Comentario contiene información no estructurada debido a que el cliente puede escribir libremente opiniones de diferente extensión, vocabulario y contenido.

Por ejemplo, una reseña puede limitarse a indicar “Excelente producto”, mientras que otra puede describir detalladamente la calidad, dimensiones, entrega o experiencia de compra. No existe un conjunto fijo de columnas capaz de representar el contenido semántico de todas las opiniones.

MongoDB permite almacenar este tipo de contenido junto con sus datos asociados dentro de un mismo documento, proporcionando flexibilidad para incorporar posteriormente otros elementos como respuestas, etiquetas, imágenes o resultados de análisis de sentimiento.



3. PREGUNTAS Y RESPUESTAS

¿Por qué una tabla relacional rígida no es adecuada para almacenar reseñas?

Porque las reseñas son texto libre y cada cliente puede escribir algo diferente. MongoDB da más flexibilidad para guardar comentarios y otros datos sin cambiar la estructura cada vez.

¿Qué ventaja ofrece JSON para un catálogo con atributos variables?

Permite que cada producto tenga sus propios atributos. Por ejemplo, una camiseta puede tener talla y un auricular puede tener Bluetooth, sin crear columnas innecesarias.

¿Cuándo conviene usar NoSQL documental en este proyecto?

Cuando los datos cambian mucho o no tienen una estructura fija, como el catálogo de productos y las reseñas de clientes.

¿Una fuente puede combinar varios tipos de información?

Sí. Por ejemplo, una reseña puede tener datos estructurados como CustomerID, fecha y calificación, junto con un comentario en texto libre que es información no estructurada.

4. CONCLUSIONES

En este laboratorio se comprendió que no todos los datos de un comercio electrónico deben almacenarse de la misma forma. Las transacciones se manejan mejor en SQL

Server por su estructura definida, mientras que MongoDB ofrece mayor flexibilidad para datos variables como el catálogo de productos y las reseñas.

También se comprobó que una misma aplicación puede combinar tecnologías relacionales y NoSQL según el tipo de información que necesite almacenar.

Bibliografía

Elmasri, R., & Navathe, S. B. (2016). *Fundamentals of database systems* (7th ed.). Pearson.

MongoDB, Inc. (2026). *MongoDB manual*. MongoDB.

Chen, D. (2012). *Online Retail II* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5CG6D>